

如果不读 Anthropic 这 15 篇技术博客，你的 Agent 开发可能正在走弯路

 mp.weixin.qq.com/s/3GJFfv2EGQ43SyT0AorhMA

CV开发者都爱看的

作者 | 队长@知乎

来源 | <https://zhuanlan.zhihu.com/p/1994463393139151039>

编辑 | 极市平台

极市导读

本文把Anthropic 官方 15 篇工程博客系统梳理为“架构-工具-上下文-协作-评测”五步学习路径，呈现从极简 Workflow 到沙箱隔离、长任务 Harness、多 Agent 编排与自动化评测的完整 Agent 工程手册，为开发者提供可复用的生产级避坑指南。>> [加入极市CV技术交流群，走在计算机视觉的最前沿](#)

今天被Anthropic新出的**Coworker**刷屏了，Anthropic发布了市面上最牛的Coding Agent：Claude Code后，他们发现，很多人用Claude Code不仅仅是完成Coding任务，还能出色的完成很多写代码以外的任务。

那么干脆就新开发了一个产品，专注于Coding以外的领域。于是Coworker就诞生了。

目前来看，Anthropic这个公司，在Agent开发上已经是遥遥领先。他们公司不仅有先进的模型，各种Agent开发方法论也是特别值得学习的。

在 AI Agent 爆发的当下，不仅开源框架（如 LangChain, AutoGen）层出不穷，各种“最佳实践”也满天飞。

然而，作为开发者，在业务落地时，我们常常陷入困惑：

- 是该用单体 Agent 还是多 Agent 协作？
- RAG 检索出来的片段上下文缺失怎么办？
- Agent 在生产环境出问题如何调试？

从 Demo 到生产的差距



知乎 @队长

与其在各种第三方框架的抽象层中迷失，不如回归本源，直接看看世界上做Agent最牛的公司都是怎么做的。

Anthropic的 Engineering Blog 是目前业界公认质量极高的技术宝库。

目前大部分市面上热门的Agent开发最佳实践，原始来源都离不开他们的博客。

我梳理出了一个阅读顺序，共15篇文章。可以顺着我推荐的这个阅读顺序进行阅读。

这 15 篇文章，不是营销宣传，而是他们用真金白银和算力堆出来的“避坑指南”。

我将这 15 篇文章梳理为 5 个核心模块，构建了一套从入门到生产环境的完整学习路径。

这些文章都不复杂，没有涉及很高深的算法逻辑，都是工程细节。

模块一：Agent 基础架构

入门篇

Start Simple

- Workflow vs Agent
- ReAct 模式
- Planning 策略

模块二：工具与能力扩展

进阶篇

Tool Use

- Tool Use 最佳实践
- Think Tool
- Agent Skills

模块三：上下文与记忆管理

核心篇

Context Window

- 上下文工程
- RAG
- Contextual Retrieval

Anthropic Agent

学习路径

17 篇文章

模块四：长任务与多 Agent

高级篇

Reliability

- 状态管理
- 多 Agent 协作
- 错误恢复机制

模块五：安全、评测与工程化

生产篇

Evals

- 安全防护
- 评测体系
- 生产监控

知乎 @队长

模块一：Agent 基础架构

复杂不代表好，从简单开始。

很多开发者一上来就想设计复杂的多智能体架构，结果系统极其脆弱。Anthropic 在基础篇中给出了最重要的建议：**Start Simple**。

- **必读文章**：《Building effective agents》
- **解读**：这篇文章详细对比了 Workflow（工作流）与 Agent 的区别，并给出了 Building Blocks（构建块）。它通过 ReAct、Tool Use 和 Planning 的基础模式告诉我们：**很多时候，你需要的只是一个定义良好的 Workflow，而不是一个不可控的 Agent。**

在此基础上，配合《Building agents with the Claude Agent SDK》，你可以快速上手构建一个“符合第一性原理”的最小可行性 Agent。

模块二：工具与能力扩展

工具不仅是 API，更是 Agent 的“四肢”；思考是 Agent 的“内存”。

Agent 与 Chatbot 的本质区别在于“工具使用”。但如何让 Agent 像人类一样灵活使用工具，甚至在遇到错误时自我修正？

- **工具设计哲学**：在《Writing effective tools for agents》中，Anthropic 强调了工具描述（Description）的重要性。这个 Description 到底怎么写，这篇文章有详细的阐述。
- **高级技巧**：当任务复杂时，《Introducing advanced tool use》展示了如何进行并行调用和嵌套调用。
- **核心神技**：《The "think" tool》是这一模块的亮点。它介绍了 CoT（思维链）的工具化——让 Agent 在行动前先“停下来想一想”。这对于需要复杂推理的场景（如代码 debug、数学解题）是质的飞跃。

模块三：上下文与记忆管理

上下文窗口虽大，但“注意力”是稀缺资源。

随着上下文窗口（Context Window）突破 200k 甚至 1M，这就意味着我们不需要 RAG 了吗？错。

- **上下文工程**：《Effective context engineering for AI agents》揭示了如何管理 Agent 的“短期记忆”与“注意力”。如何通过 Prompt 结构化让模型在长对话中不迷失，是每个 Agent 开发者的必修课。
- **RAG 的进化**：《Introducing Contextual Retrieval》提出了一个想法——**Contextual Retrieval**（上下文检索）。传统的 RAG 切片会丢失上下文（例如切片中只有“他同意了”，却不知道“他”是谁）。通过让模型在切片前先生成一段解释性上下文，检索准确率得到了惊人的提升。这是目前 RAG 领域的 State-of-the-Art 实践。

模块四：长跑与协作——长任务与多 Agent

| Demo 只要跑通一次，产品需要跑通一万次。

当 Agent 从 3 秒的对话变成运行 3 小时的任务时，挑战完全变了。

- **可靠性工程**：《Effective harnesses for long-running agents》讨论了如何为长时间运行的 Agent 设计 Harness。如何处理中断？如何保存状态？如何从死循环中恢复？这是从 Demo 迈向生产环境的关键。
- **多智能体协作**：在《How we built our multi-agent research system》中，Anthropic 分享了内部构建多 Agent 系统的架构。这对于需要 Orchestrator-Workers 模式的复杂项目极具参考价值。

模块五：最后的一公里——安全、评测与工程化

| 没有 Evals（评测），就不要上线。

这是最枯燥，但也是区分“Demo”和“工业级 Agent”的模块。

- **评测体系**：《Demystifying evals for AI agents》是全系列的必读之作。它打破了“看感觉”的开发模式，建立了一套基于 LLM 评分的自动化测试体系。
- **安全沙箱**：当赋予 Agent 编写和执行代码的能力时（如《Claude Code: Best practices for agentic coding》），安全风险指数级上升。《Beyond permission prompts》和《Code execution with MCP》展示了如何通过沙箱（Sandboxing）和 MCP 协议，在赋予 Agent 自由的同时，给它戴上“镣铐”。
- **失败复盘**：《A postmortem of three recent issues》通过三个真实的故障案例，展示了 Agent 在真实世界中会如何“花式犯错”，这是花钱买不来的实战经验。

结语：站在巨人的肩膀上

Anthropic 的这 17 篇文章，实际上构成了一份 **Agent Engineering Handbook**（Agent 工程手册）。



如果你正在构建 Agent，必须读读这15篇文章，并按照**架构 -> 工具 -> 上下文 -> 协作 -> 评测**的顺序研读。在这个日新月异的领域，盲目追逐新框架不如深挖底层逻辑，因为**工具会变，但工程原理永存**。

(附：完整的 15篇文章清单及分类) Anthropic Agent 最佳实践系列

模块一：Agent 基础架构（入门篇）

#	参考文章	内容	核心价值
1	Building effective agents (https://www.anthropic.com/engineering/building-effective-agents)	Agent 架构入门：从单轮对话到自主代理	理解 Agent 的基本模式：ReAct、Tool Use、Planning

# 参考文章	内容	核心价值
2 Building agents with the Claude Agent SDK (https://www.anthropic.com/engineering/building-agents-with-the-claude-agent-sdk)	用 Agent SDK 构建你的第一个 Agent	实战入门，快速上手

模块二：工具与能力扩展（进阶篇）

# 参考文章	内容	核心价值
3 Introducing advanced tool use (https://www.anthropic.com/engineering/advanced-tool-use)	Agent 高级工具调用：并行、嵌套与错误处理	工具调用的进阶技巧
4 Writing effective tools for agents — with agents (https://www.anthropic.com/engineering/writing-tools-for-agents)	如何为 Agent 设计好用的工具	工具设计原则和最佳实践
5 The "think" tool (https://www.anthropic.com/engineering/claude-think-tool)	Think Tool : 让 Agent 学会"停下来想一想"	复杂推理场景的关键技巧
6 Equipping agents for the real world with Agent Skills (https://www.anthropic.com/engineering/equipping-agents-for-the-real-world-with-agent-skills)	Agent Skills : 让 Agent 具备真实世界能力	技能封装与复用

模块三：上下文与记忆管理（核心篇）

# 参考文章	内容	核心价值
7 Effective context engineering for AI agents (https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents)	上下文工程：Agent 的"记忆"与"注意力"管理	长对话、多轮任务的关键

# 参考文章	内容	核心价值
8 Introducing Contextual Retrieval (https://www.anthropic.com/engineering/contextual-retrieval)	Contextual Retrieval：让 RAG 更懂上下文	检索增强的新范式

模块四：长任务与多 Agent（高级篇）

# 参考文章	内容	核心价值
9 Effective harnesses for long-running agents (https://www.anthropic.com/engineering/effective-harnesses-for-long-running-agents)	长时间运行的 Agent：如何设计可靠的执行框架	任务中断恢复、状态持久化
10 How we built our multi-agent research system (https://www.anthropic.com/engineering/multi-agent-research-system)	多 Agent 协作系统：Anthropic 的实战经验	多 Agent 架构设计
11 Code execution with MCP (https://www.anthropic.com/engineering/code-execution-with-mcp)	MCP 代码执行：构建更高效的 Agent	Agent 执行环境设计

模块五：安全、评测与工程化（生产篇）

# 参考文章	内容	核心价值
12 Demystifying evals for AI agents (https://www.anthropic.com/engineering/demystifying-evals-for-ai-agents)	Agent 评测怎么做	评测体系设计
13 Beyond permission prompts: Claude Code sandboxing (https://www.anthropic.com/engineering/claude-code-sandboxing)	Agent 安全：从权限提示到沙箱隔离	安全与自主性的平衡
14 Claude Code: Best practices for agentic coding (https://www.anthropic.com/engineering/claude-code-best-practices)	Coding Agent 最佳实践	Coding Agent 的工程经验
15 A postmortem of three recent issues (https://www.anthropic.com/engineering/a-postmortem-of-three-recent-issues)	Agent 故障复盘：三个真实案例分析	从失败中学习