

跟随 Karpathy 理解大模型的深刻变革

mp.weixin.qq.com/s/MXZ1mc8D_WIDABGrAhi3qA

aC大

引言：2025 年的范式转变

2025 年，对于大型语言模型（LLM）领域而言，不仅是技术迭代加速的一年，更是一个深刻的认知重构之年。作为业界思想的敏锐观察者，Andrej Karpathy 在其年度总结 中，为我们描绘了一幅由一系列“范式转变”构成的全新图景。他指出，我们正从根本上改变对人工智能本质的理解，其发展路径、应用形态乃至社会影响，都呈现出与以往截然不同的特征。本文将引 Karpathy 的视角为引，深入剖析他如何理解大模型的发展，串联其一系列深刻洞见，揭示一个从“召唤幽灵”到“权力归于人民”的 AI 新时代。



召唤幽灵而非驯化动物——对 LLM 智能本质的重新认识

长期以来，我们习惯于用生物学的隐喻来理解人工智能，期望能“培育”或“进化”出类似动物甚至人类的智能。然而，Karpathy 尖锐地指出，这是一种根本性的误解。今天的前沿 LLM 研究，“不是在构建动物，而是在召唤幽灵”。这一论断构成了他理解 LLM 的核心基石。

“苦涩教训”的争议与“幽灵”的诞生

Rich Sutton 的《苦涩教训》一文被 LLM 研究者奉为圭臬，其核心思想是真正的智能进步源于通用方法在更多计算资源下的扩展。但 Karpathy 援引 Sutton 本人的疑虑，对 LLM 是否完全遵循此原则提出了挑战。LLM 依赖于人类生成的、有限且充满偏见的互联网文本进行预训练，这与动物在真实世界中通过经验自主学习的模式截然不同。这种依赖人类“文化遗产”的特性，使得 LLM 成为人类心智的“统计提炼”，是渗透了人类痕迹的“不完美复制品”。

Karpathy 将这种非生物、非自主进化而来的智能形态命名为“幽灵”（Ghosts）。它们并非从零开始学习，而是通过“预训练”这一“糟糕的进化”（crappy evolution）方案，解决了智能的冷启动问题。正如小斑马出生几十分钟便能奔跑，其能力源于 DNA 中编码的强大初始化，而非白板一块的随机学习；LLM 的预训练，正是利用海量人类文档，为模型的数十亿参数提供了必要的初始约束。

智能空间中的不同坐标：优化压力的分野


“幽灵”与“动物”的本质区别，源于它们在广阔“智能空间”中所处的不同坐标，而这坐标是由截然不同的优化压力决定的。

智能类型	核心驱动力	优化目标	根本目的
动物智能	生物进化	自然选择	在危险的物理世界中维持内稳态与族群存续
LLM 智能（幽灵）	商业进化	梯度下降、A/B 测试	解决特定问题、获得用户认可（“点赞”）

动物智能为了生存，必须发展出通用的、鲁棒的能力，任何任务的失败都可能意味着死亡。而 LLM 的失败（例如无法正确数出单词中的字母）并不会带来生存危机，其优化目标是迎合特定的、可验证的任务奖励和用户偏好。这种优化压力的差异，决定了 LLM 必然会展现出与动物截然不同的智能形态，我们必须放弃用“拟人化”或“拟动物化”的视角去揣度它，否则将产生巨大的认知偏差。

可验证性——理解 AI 能力边界的关键

如果说“幽灵”隐喻重塑了我们对 LLM 本质的认知，那么“可验证性”（Verifiability）则是 Karpathy 用来解释其能力边界的核心标尺。它精准地预测了为何 LLM 的智能表现如此“参差不齐”（Jagged Intelligence）。



从“可指定性”到“可验证性”的范式跃迁

Karpathy 提出了软件发展的两个阶段，其自动化能力的核心判断标准发生了根本变化：

- Software 1.0 (手写程序)：其自动化能力取决于任务的“可指定性”，即能否将任务拆解为明确、机械的算法步骤，如记账、打字。
- Software 2.0 (AI 驱动的程序)：其自动化能力取决于任务的“可验证性”，即我们能否为任务设定一个可自动评估的目标（奖励函数），让 AI 通过海量“练习”自行寻找解决方案。

一个任务的可验证性越高，AI 的表现就越可能超越人类顶尖专家。这需要任务环境满足三个条件：可重置（能开启新尝试）、高效（可进行大量尝试）和可奖励（有自动化机制为结果打分）。

RLVR 的崛起与“参差不齐的智能”

2025 年，基于可验证奖励的强化学习（RLVR）成为 LLM 训练的新阶段。通过在数学、编程等高可验证性环境中进行长时间优化，LLM 自发地发展出了类似人类“推理”的策略。同时，这也催生了 LLM “参差不齐的智能”现象：它既能解决复杂的数学难题，又可能在“9.11 和 9.9 哪个数字大”这类简单问题上犯错。这种能力的巨大反差，正源于不同任务可验证性的差异。

Karpathy 认为，这种现象的根源在于模型缺乏“认知自我认知”（cognitive self-knowledge），即模型不知道自己知道什么、不知道什么。这也导致了传统基准测试的“信任危机”，因为基准测试本质上是高度可验证的环境，极易被针对性优化，从而出现“碾压所有基准但仍未获得 AGI”的局面。

Software 3.0——应用层的厚度与智能体的十年

随着 LLM 能力的演进，一个新的软件范式——Software 3.0——正在形成。Karpathy 在其 YC 演讲 中系统阐述了这一新范式，其核心特征是自然语言成为新的编程接口，而 LLM 则扮演着新型计算机的角色。

Cursor 揭示的应用层

以 Cursor 为代表的“LLM 应用”的崛起，证明了在基础大模型之上，存在一个足够“厚”的应用层。这类应用并非简单地调用 API，而是扮演着复杂的“编排者”角色：

- 进行上下文工程：智能地收集和组织与任务相关的信息。
- 编排多 LLM 调用：在后台将多个 LLM 调用串联成复杂的任务流（DAGs）。
- 提供应用专属 GUI：为“人在环路”中的验证环节提供高效的图形界面。
- 提供“自主滑块”：允许用户根据任务需求动态调整 AI 的自主程度。

部分自主性与“为智能体构建”

Karpathy 强调，当前我们正处于“部分自主性”（Partial Autonomy）的阶段，而非完全自主的智能体时代。他用“钢铁侠战衣”来比喻人与 AI 的理想关系——AI 既能增强人类能力，又能在特定时刻自主行动。然而，从一个炫酷的演示（Demo）到一个可靠的产品（Product）之间存在巨大的鸿沟，即“Demo is works.any(), product is works.all()”。

因此，未来的关键在于“为智能体构建”。这意味着我们的数字基础设施需要认识到除了人类（GUI）和计算机（API）之外，还存在第三类信息消费者——智能体。无论是 API 设计还是文档格式（如从 HTML 转向 Markdown），都需要变得对 LLM 更加友好，以降低其理解和操作世界的门槛。

权力的重新分配——技术扩散的历史性逆转

LLM 最令人瞩目且出乎意料的社会影响，在于它彻底颠覆了传统技术的扩散模式，实现了 Karpathy 所说的“权力归于人民”（Power to the people）。

从“自上而下”到“自下而上”

历史上，从电力到互联网，几乎所有颠覆性技术都遵循“政府/军事 → 企业 → 个人”的“自上而下”扩散路径。因为早期技术通常资本密集、操作复杂。而 LLM 却呈现出戏剧性的逆转：普通人成为首要且最大的受益者，其影响在企业和政府层面反而更为温和与滞后。

为何普通人受益更多？

Karpathy 认为，核心原因在于 LLM “广谱准专家”的能力特性与个人及组织需求的匹配度差异：

- 对于个人：个人通常只精通少数领域。LLM 的广谱能力使其能突破个人能力边界，完成以前无法独立完成任务（如非专业人士编写代码、解读法律文件），实现能力的根本性突破。
- 对于组织：组织的核心优势在于聚合各类专家。LLM 更多是提升专家个体的效率，是在组织原有能力上的边际优化，而非带来能力上的质变。同时，组织的复杂性、合规要求和固有惯性也使其难以快速拥抱一个“多才多艺但浅薄且易出错”的新工具。

这一历史性的模式反转，使得普通人正经历一场前所未有的、快速而剧烈的技术赋能。正如 Karpathy 所言：“未来已经到来，而且分布得令人震惊地均匀。”

结语：既聪明又愚笨，潜力未及十分之一

在 Karpathy 的描绘下，LLM 不再是一个通向通用人工智能的线性阶梯，而是一个充满悖论、机遇和全新挑战的复杂生态。它既比我们想象的更聪明，又比我们想象的更愚笨。它像一个“幽灵”，其行为由商业进化而非生物进化塑造；它的能力边界由“可验证性”清晰界定；它催生了 Software 3.0 的新范式，并以前所未有的方式将技术权力赋予普通大众。

从“Vibe Coding”（氛围编程）让全民编程成为可能，到“Nano Banana”预示着 LLM 的 GUI 革命，我们正处在一个新计算范式的黎明。Karpathy 坚信，尽管 LLM 已经极其有用，但整个行业对其潜力的挖掘“还不到 10%”。未来十年将是“智能体的十年”，重点不在于遥远的 AGI 幻想，而在于打磨更多具有“部分自主性”的实用产品。

通过 Karpathy 的视角，我们得以跳出单纯的技术参数竞赛，从一个更宏大、更深刻的框架中理解这场正在发生的革命。我们正在学习如何与一种全新的非动物智能共存、协作，并驾驭它为世界带来的深刻变革。

参考文献

[1] Karpathy, A. (2025, December 19). 2025 LLM Year in Review.

[2] Karpathy, A. (2025, October 1). Animals vs Ghosts.

[3] Karpathy, A. (2025, November 29). The space of minds.

[4] Karpathy, A. (2025, November 17). Verifiability.

[5] Wang, S. (2025, June 17). Andrej Karpathy on Software 3.0: Software in the Age of AI. Latent Space.

[6] Karpathy, A. (2025, April 7). Power to the people: How LLMs flip the script on technology diffusion.